

Análisis Descriptivo y Diagnóstico de Ventas de Videojuegos con Python

Massielle Coti

Table of contents

1	Introducción	2
2	Objetivos de aprendizaje	2
3	Parte A: Carga y exploración inicial	2
3.1	Tarea A.1: Importar paquetes y cargar el dataset	2
3.2	Tarea A.2: Preguntas de exploración inicial	3
3.3	Tarea A.3: Primeras filas y estadísticas descriptivas	4
4	Parte B: Limpieza de datos	4
4.1	Tarea B.1: Transformaciones	4
4.2	Tarea B.2: Justificación de la limpieza	5
5	Parte C: Análisis descriptivo	5
5.1	Tarea C.1: Ventas globales por género	5
5.2	Tarea C.2: Tendencia anual de ventas globales	6
5.3	Tarea C.3: Ventas totales por región	7
5.4	Tarea C.4: Top 10 publishers	7
5.5	Tarea C.5: Visualizaciones	8
5.5.1	Gráfico de barras: ventas por género	8
5.5.2	Gráfico de línea: tendencia anual	8
5.5.3	Gráfico circular: participación por región	8
5.5.4	Gráfico de barras horizontal: Top 10 publishers	8
5.6	Tarea C.6: Interpretación descriptiva	8
6	Parte D: Análisis diagnóstico	12
6.1	Tarea D.1: Distribución regional por género	12
6.2	Tarea D.2: Ciclo de vida de las plataformas	13

6.3	Tarea D.3: Concentración del mercado por publisher	13
6.4	Tarea D.4: Pregunta diagnóstica propia	14
7	Parte E: Interpretación administrativa	15
7.1	Tarea E.1: Informe ejecutivo	15
7.2	Tarea E.2: Reflexión administrativa	16
8	5. Extensiones	16
8.1	Extensión elegida: Regresión lineal para predecir ventas globales	16
9	Conclusiones	17

1 Introducción

En esta práctica se aplica un ciclo completo de análisis de datos sobre el dataset `vgsales.csv`, que contiene información histórica de ventas de videojuegos a nivel global. El objetivo es transformar datos crudos en información útil para la toma de decisiones, combinando análisis descriptivo (¿qué pasó?) y diagnóstico (¿por qué pasó?).

2 Objetivos de aprendizaje

- Importar y limpiar datos reales usando `pandas`.
- Aplicar técnicas descriptivas para resumir información de ventas.
- Aplicar técnicas diagnósticas para explicar patrones observados.
- Generar visualizaciones efectivas con `matplotlib`, `seaborn` y `plotly`.
- Interpretar resultados desde una perspectiva de toma de decisiones.

3 Parte A: Carga y exploración inicial

3.1 Tarea A.1: Importar paquetes y cargar el dataset

	Rank	Name	Platform	Year	Genre	Publisher	NA_Sales	EU_Sa
0	1	Wii Sports	Wii	2006.0	Sports	Nintendo	41.49	29.02
1	2	Super Mario Bros.	NES	1985.0	Platform	Nintendo	29.08	3.58
2	3	Mario Kart Wii	Wii	2008.0	Racing	Nintendo	15.85	12.88
3	4	Wii Sports Resort	Wii	2009.0	Sports	Nintendo	15.75	11.01
4	5	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	Nintendo	11.27	8.89

3.2 Tarea A.2: Preguntas de exploración inicial

¿Cuántas filas y columnas tiene el dataset?

El dataset tiene **16,598** filas y **11** columnas (antes de limpieza).

¿Qué tipo de datos tiene cada columna?

Columna	Tipo	Descripción
Rank	int64	Ranking de ventas globales
Name	object	Nombre del videojuego
Platform	object	Plataforma (PS4, X360, etc.)
Year	float64	Año de lanzamiento
Genre	object	Género (Action, Sports, etc.)
Publisher	object	Distribuidora
NA_Sales	float64	Ventas en Norteamérica (millones USD)
EU_Sales	float64	Ventas en Europa (millones USD)
JP_Sales	float64	Ventas en Japón (millones USD)
Other_Sales	float64	Ventas en otras regiones (millones USD)
Global_Sales	float64	Ventas globales totales (millones USD)

¿Qué representa cada columna?

Cada fila representa un videojuego y sus ventas desagregadas por región. **Global_Sales** es la suma de las cuatro regiones. **Rank** es un identificador ordinal basado en ventas.

¿Hay valores nulos? ¿En qué columnas?

Sí. Las columnas con valores nulos son:

```
Rank          0
Name          0
Platform      0
Year         271
Genre         0
Publisher     58
NA_Sales      0
EU_Sales      0
JP_Sales      0
Other_Sales   0
Global_Sales  0
dtype: int64
```

Principalmente **Year** (271 nulos) y **Publisher** (58 nulos).

3.3 Tarea A.3: Primeras filas y estadísticas descriptivas

	Rank	Name	Platform	Year	Genre	Publisher	NA_Sales	EU_Sa
0	1	Wii Sports	Wii	2006.0	Sports	Nintendo	41.49	29.02
1	2	Super Mario Bros.	NES	1985.0	Platform	Nintendo	29.08	3.58
2	3	Mario Kart Wii	Wii	2008.0	Racing	Nintendo	15.85	12.88
3	4	Wii Sports Resort	Wii	2009.0	Sports	Nintendo	15.75	11.01
4	5	Pokemon Red/Pokemon Blue	GB	1996.0	Role-Playing	Nintendo	11.27	8.89
5	6	Tetris	GB	1989.0	Puzzle	Nintendo	23.20	2.26
6	7	New Super Mario Bros.	DS	2006.0	Platform	Nintendo	11.38	9.23
7	8	Wii Play	Wii	2006.0	Misc	Nintendo	14.03	9.20
8	9	New Super Mario Bros. Wii	Wii	2009.0	Platform	Nintendo	14.59	7.06
9	10	Duck Hunt	NES	1984.0	Shooter	Nintendo	26.93	0.63

	Rank	Year	NA_Sales	EU_Sales	JP_Sales	Other_Sales	Global_Sales
count	16598.000000	16327.000000	16598.000000	16598.000000	16598.000000	16598.000000	16598.000000
mean	8300.605254	2006.406443	0.264667	0.146652	0.077782	0.048063	0.537441
std	4791.853933	5.828981	0.816683	0.505351	0.309291	0.188588	1.555028
min	1.000000	1980.000000	0.000000	0.000000	0.000000	0.000000	0.010000
25%	4151.250000	2003.000000	0.000000	0.000000	0.000000	0.000000	0.060000
50%	8300.500000	2007.000000	0.080000	0.020000	0.000000	0.010000	0.170000
75%	12449.750000	2010.000000	0.240000	0.110000	0.040000	0.040000	0.470000
max	16600.000000	2020.000000	41.490000	29.020000	10.220000	10.570000	82.740000

4 Parte B: Limpieza de datos

4.1 Tarea B.1: Transformaciones

Valores nulos después de limpieza:

```
Rank      0
Name      0
Platform  0
Year      0
Genre     0
Publisher 0
NA_Sales  0
EU_Sales  0
JP_Sales  0
```

```
Other_Sales      0
Global_Sales     0
dtype: int64
```

Dimensiones finales: (16327, 11)

4.2 Tarea B.2: Justificación de la limpieza

¿Por qué es importante limpiar los datos antes de analizarlos?

Porque los datos crudos suelen contener errores, duplicados y valores faltantes que distorsionan los cálculos. Un análisis sobre datos sucios produce conclusiones erróneas y decisiones administrativas equivocadas.

¿Qué decisiones tomó sobre los valores nulos y por qué?

- **Year:** se eliminaron las filas porque el año es clave para el análisis de tendencias. Imputarlo introduciría sesgo temporal.
- **Publisher:** se reemplazó por "Unknown" para no perder ventas asociadas a esos juegos.

¿Qué impacto podría tener no limpiar los datos?

Se sobreestimarían o subestimarían ventas por género, año o publisher; los gráficos mostrarían ruido; y las recomendaciones administrativas serían poco confiables.

Reflexión: Si este dataset representara ventas reales de una empresa, tomar decisiones con datos sin limpiar implicaría riesgos como invertir en géneros equivocados, mal asignar presupuesto por región o perder credibilidad ante la gerencia.

5 Parte C: Análisis descriptivo

5.1 Tarea C.1: Ventas globales por género

	Genre	Global_Sales
0	Action	1722.88
1	Sports	1309.24
2	Shooter	1026.20
3	Role-Playing	923.84
4	Platform	829.15
5	Misc	797.62
6	Racing	726.77
7	Fighting	444.05

	Genre	Global_Sales
8	Simulation	390.16
9	Puzzle	242.22
10	Adventure	234.80
11	Strategy	173.43

5.2 Tarea C.2: Tendencia anual de ventas globales

	Year	Global_Sales
0	1980	11.38
1	1981	35.77
2	1982	28.86
3	1983	16.79
4	1984	50.36
5	1985	53.94
6	1986	37.07
7	1987	21.74
8	1988	47.22
9	1989	73.45
10	1990	49.39
11	1991	32.23
12	1992	76.16
13	1993	45.98
14	1994	79.17
15	1995	88.11
16	1996	199.15
17	1997	200.98
18	1998	256.47
19	1999	251.27
20	2000	201.56
21	2001	331.47
22	2002	395.52
23	2003	357.85
24	2004	419.31
25	2005	459.94
26	2006	521.04
27	2007	611.13
28	2008	678.90
29	2009	667.30
30	2010	600.45

	Year	Global_Sales
31	2011	515.99
32	2012	363.54
33	2013	368.11
34	2014	337.05
35	2015	264.44
36	2016	70.93
37	2017	0.05
38	2020	0.29

5.3 Tarea C.3: Ventas totales por región

	Región	Ventas
0	NA	4333.43
1	EU	2409.12
2	JP	1284.30
3	Other	789.01

5.4 Tarea C.4: Top 10 publishers

	Publisher	Global_Sales
0	Nintendo	1784.43
1	Electronic Arts	1093.39
2	Activision	721.41
3	Sony Computer Entertainment	607.28
4	Ubisoft	473.54
5	Take-Two Interactive	399.30
6	THQ	340.44
7	Konami Digital Entertainment	278.56
8	Sega	270.70
9	Namco Bandai Games	253.65




Figure 1: Ventas globales por género (millones USD)

5.5 Tarea C.5: Visualizaciones

5.5.1 Gráfico de barras: ventas por género

5.5.2 Gráfico de línea: tendencia anual

5.5.3 Gráfico circular: participación por región

5.5.4 Gráfico de barras horizontal: Top 10 publishers

5.6 Tarea C.6: Interpretación descriptiva

¿Cuál es el género más vendido? ¿Por qué cree que es así?

El género **Action** lidera las ventas globales, seguido de **Sports** y **Shooter**. Esto se explica porque Action abarca una audiencia amplia, tiene bajo costo de entrada y domina las consolas más populares.

¿En qué año se alcanzó el pico máximo de ventas?




Figure 2: Tendencia anual de ventas globales

El pico se alcanzó alrededor de **2008-2009**, coincidiendo con el auge de consolas como Wii, PS3 y Xbox 360, y con lanzamientos masivos de franquicias deportivas y de acción.

¿Qué región concentra la mayor parte de las ventas?

Norteamérica (NA) concentra la mayor parte, seguida de Europa. Japón, aunque relevante, representa una fracción menor del mercado global.

¿Qué publisher domina el mercado?

Nintendo domina ampliamente, seguido de **Electronic Arts** y **Activision**.




Figure 3: Participación de ventas por región





Figure 4: Top 10 publishers por ventas globales

6 Parte D: Análisis diagnóstico


6.1 Tarea D.1: Distribución regional por género



Pregunta D.1: El género con proporción inusualmente alta en Japón es **Role-Playing (RPG)**. Esto se explica por la fuerte tradición cultural japonesa de juegos narrativos (Final

Fantasy, Dragon Quest, Pokémon), el gusto por historias largas y el mercado doméstico de consolas portátiles.


6.2 Tarea D.2: Ciclo de vida de las plataformas



Pregunta D.2: Las plataformas muestran un ciclo típico de ~7-10 años: lanzamiento, crecimiento, pico y declive. Esto obliga a las desarrolladoras a planificar migraciones tecnológicas y a diversificar en múltiples plataformas para no depender de una sola.

6.3 Tarea D.3: Concentración del mercado por publisher


Top 5 publishers concentran: 53.06%
Top 10 publishers concentran: 70.55%
Top 20 publishers concentran: 85.64%



Pregunta D.3: El mercado está **concentrado**: el Top 10 concentra más del 60% de las ventas. Para un nuevo publisher esto implica alta barrera de entrada, necesidad de nichos diferenciados (indie, móvil, RPG japonés) y alianzas estratégicas.

6.4 Tarea D.4: Pregunta diagnóstica propia

Pregunta: ¿Los juegos más vendidos tienden a concentrarse en pocos años?



Conclusión: Sí. Los juegos más vendidos se concentran entre **2006 y 2010**, coincidiendo con el pico de la industria y el ciclo de vida de consolas masivas (Wii, DS, PS3, X360). Esto sugiere que el éxito comercial depende fuertemente del contexto tecnológico y de la base instalada de consolas.

7 Parte E: Interpretación administrativa

7.1 Tarea E.1: Informe ejecutivo

Resumen ejecutivo

1. El género **Action** lidera las ventas globales, con **Sports** y **Shooter** muy cerca.
2. **Norteamérica y Europa** concentran más del 70% de las ventas globales.
3. **Nintendo** domina el mercado, y el Top 10 de publishers concentra más del 60% de las ventas.

Análisis descriptivo

Los datos muestran que la industria del videojuego está fuertemente concentrada en pocos géneros y pocos publishers. El pico de ventas ocurrió entre 2008 y 2009, impulsado por consolas masivas y franquicias anuales (deportes, shooters). Japón, aunque es un mercado menor en volumen global, tiene preferencias muy marcadas por RPG y juegos narrativos.

Análisis diagnóstico

La concentración del mercado se explica por economías de escala, presupuestos de marketing masivos y franquicias consolidadas. El ciclo de vida de las plataformas (~7-10 años) obliga a las empresas a planificar migraciones tecnológicas. La preferencia japonesa por RPG responde a factores culturales e históricos.

Recomendaciones

1. **Invertir en Action y Shooter** para mercados NA/EU, donde está el mayor volumen.
2. **Explorar nichos de RPG y juegos narrativos** para el mercado japonés y asiático.
3. **Diversificar plataformas** para mitigar el riesgo del ciclo de vida de consolas.

Limitaciones

El dataset no incluye ventas digitales, microtransacciones, ni datos posteriores a 2017. Tampoco permite inferir causalidad, solo correlación. No hay información de costos, márgenes ni satisfacción del cliente.

7.2 Tarea E.2: Reflexión administrativa

¿Cómo se relaciona este análisis con la toma de decisiones en una empresa real?

Permite priorizar géneros, regiones y plataformas según evidencia, reducir riesgo de inversión y justificar presupuestos ante la gerencia.

¿Qué otras fuentes de datos utilizaría para enriquecer el análisis?

Ventas digitales, datos de Steam/PSN/Xbox Live, encuestas de satisfacción, costos de desarrollo, datos de marketing y tendencias en redes sociales.

¿Qué riesgos éticos podría identificar?

Sesgo por falta de datos digitales, posible discriminación de mercados pequeños, uso de datos sin consentimiento y dependencia de métricas puramente comerciales.

8 5. Extensiones

8.1 Extensión elegida: Regresión lineal para predecir ventas globales

R^2 : 1.0000

R^2 : 1.0000

RMSE: 0.0052

Coeficientes: [0.99994542 0.99983422 1.00007406 0.9993494]

Intercepto: 0.0003

Análisis: El modelo muestra un R^2 cercano a 1, lo que confirma que `Global_Sales` es prácticamente la suma de las ventas regionales. Esto es esperado por construcción del dataset, pero valida la consistencia de los datos.

Conclusión: La regresión confirma que las ventas regionales explican casi toda la varianza de las ventas globales. Para predecir ventas futuras se necesitarían variables exógenas (marketing, precio, plataforma, competencia).

9 Conclusiones

Este análisis permitió transformar un dataset crudo de ventas de videojuegos en información accionable. Se identificaron patrones claros: dominancia del género Action, concentración del mercado en pocos publishers, liderazgo de Norteamérica y Europa, y preferencias culturales marcadas en Japón hacia RPG.

Desde una perspectiva administrativa, los hallazgos sugieren que una empresa del sector debe diversificar plataformas, priorizar géneros con mayor volumen y adaptar su portafolio a cada región. El análisis diagnóstico mostró que el éxito comercial está fuertemente ligado al ciclo de vida de las consolas y al contexto tecnológico de cada época.

Las limitaciones del dataset (ausencia de ventas digitales, datos hasta 2017, falta de costos y márgenes) implican que las decisiones deben complementarse con otras fuentes. Sin embargo, el ejercicio demuestra el valor del análisis de datos para reducir incertidumbre y fundamentar estrategias en evidencia.