

Preprocesamiento de datos

Massielle Coti

2026-07-16

Carga de datos

¿Como visualizamos los primeros datos?

When you click the **Knit** button a document will be generated that includes both content as well as the output of any embedded R code chunks within the document. You can embed an R code chunk like this:

```
## , , Age = Child, Survived = No
##
##      Sex
## Class  Male Female
## 1st      0      0
## 2nd      0      0
## 3rd     35     17
## Crew      0      0
##
## , , Age = Adult, Survived = No
##
##      Sex
## Class  Male Female
## 1st   118      4
## 2nd   154     13
## 3rd   387     89
## Crew  670      3
##
## , , Age = Child, Survived = Yes
##
##      Sex
## Class  Male Female
## 1st      5      1
## 2nd     11     13
## 3rd     13     14
## Crew      0      0
##
## , , Age = Adult, Survived = Yes
##
##      Sex
## Class  Male Female
## 1st     57    140
## 2nd     14     80
## 3rd     75     76
## Crew   192     20
```

¿Como hacemos para saber de que tipo son los datos (texto/numero)?

```
## 'table' num [1:4, 1:2, 1:2, 1:2] 0 0 35 0 0 0 17 0 118 154 ...
## - attr(*, "dimnames")=List of 4
## ..$ Class : chr [1:4] "1st" "2nd" "3rd" "Crew"
## ..$ Sex : chr [1:2] "Male" "Female"
## ..$ Age : chr [1:2] "Child" "Adult"
## ..$ Survived: chr [1:2] "No" "Yes"
```

Limpieza de datos

¿Cuántos datos faltantes hay para la variable edad (Age)?

```
## [1] 177
```

Si los eliminamos perdemos demasiada información ¿Que hacemos?

Solución: **Imputarlos** (imputar a la Media o la Mediana) Recordatorio: La media se ve afectada por los *valores atípicos (outliers)*

Análisis Exploratorio de datos (EDA) con gráficos

Como determinamos si los niños ($\text{Age} < 12$) sobrevivieron más? generamos una columna llamada 'Child'

Nivel 1: R Base (Sin incluir ningún paquete)

Ideal para entender la lógica sin dependencias

Tabla de contingencia (Frecuencias)

Cuánto hombres y mujeres sobrevivieron?


```
##
##           0    1
## female  81 233
## male    468 109
```

```
##
##           0          1
## female 25.79618 74.20382
## male   81.10919 18.89081
```

Box Plot (Edad vs Supervivencia)


La edad de los que sobrevivieron es similar a la edad de las que no lo hicieron?

Distribucion de edad por supervivencia




Barplot de supervivencia por clase

La clase influyo en la supervivencia?



porcentaje de cada clase sobrevivio?

Supervivencia por clase del pasajero



Nivel 2: GGLOT2 (Mas profesional y estetico)

Boxplot con ggplot2 (el mas utilizado)

Que grupo tiene mayor edad? (observar las madianas)

Distribución de edad por supervivencia




Grafico de barras porcentuales (Mejor para hacer comparacion) Que clase tuvo el mayor numero de supervivientes?

Supervivencia por clase

La 1.^a clase tuvo más supervivientes en números absolutos





Grafico de barras porcentuales (Mejor para hacer comparacion) Que clase tuvo el mayor porcentaje de supervivencia?

Supervivencia por clase

La 1.^a clase tuvo más supervivientes en números absolutos




Relacion entre Edad, Clase y Supervivencia (Mas avanzado)

Los niños de la 3a. clase tuvieron la misma oportunidad de supervivencia que los niños de la 1a. clase?

Distribución por Edad, Clase y Supervivencia

Los niños de la 1.^a y 2.^a clase sobrevivieron más que los de la 3.^a clase



Nivel 3: DPLYR + GGLOT (Flujo de trabajo profesional) Encadenar procesos de trabajo (pipe)

1. Calcular la tasa de supervivencia por genero y clase.


```
##
## Attaching package: 'dplyr'
```

```
## The following objects are masked from 'package:stats':
##
##   filter, lag
```

```
## The following objects are masked from 'package:base':
##
##   intersect, setdiff, setequal, union
```

```
## # A tibble: 6 × 6
##   Sex    Pclass Sobrevivieron Total Tasa_supervivencia Edad_media
##   <fct> <fct>      <int> <int>          <dbl>         <dbl>
## 1 female 1           91    94           96.8          34.1
## 2 female 2           70    76           92.1          28.7
## 3 female 3           72   144           50           24.1
## 4 male   1           45   122           36.9          39.3
## 5 male   2           17   108           15.7          30.7
## 6 male   3           47   347           13.5          27.4
```

```
## Ignoring unknown labels:
## • tittle : "Tasa de Supervivencia por Genero y Clase"
```




Visualizaciones multiples

Con GGPLOT y GridExtra

```
##
## Attaching package: 'gridExtra'
```

```
## The following object is masked from 'package:dplyr':
##
## combine
```

Distribución de edad por supervivencia




Supervivencia por clase

La 1.ª clase tuvo más supervivientes en núm




Supervivencia por clase

La 1.ª clase tuvo más supervivientes en




Distribución por Edad, Clase y Supervivencia

Los niños de la 1.ª y 2.ª clase sobrevivieron



Con R base

Boxplot de Supervivencia



Clase Vs. Supervivencia

